1. 稀疏矩阵

2. 鲁棒性

3. L1和I2正则化的区别

简单来说也就是范数其实在 [0,∞)范围内的值,是向量的投影大小,在机器 学习中一般会用于衡量向量的距离。范数有很多种,我们常见的有L1-norm 和L2-norm,其实还有L3-norm、L4-norm等等,所以抽象来表示,我们会 写作Lp-norm,一般表示为

$$||x||_p = (\sum_i |x_i|^p)^{1/p}$$

对于上面这个抽象的公式,如果我们代入p值,


若p为1,则就是我们常说的L1-norm:


$$||x||_1 = \sum_i |x_i| = |x_1| + |x_2| + \ldots + |x_i|$$

若p为2,则是我们常说的L2-norm:

$$||x||_2 = \sqrt{(\sum_i |x_i|^2)} = \sqrt{x1^2 + x2^2 + \ldots + x_i^2}$$

L2-norm的距离就是两个黑点之间的绿线,而另外的3条线,都是L1-norm







 (x_2,y_2) $(x_2$ 红维(X2-X1)+(J2-Y)=121+12 建结与其线片是组结的变形,筑的距离不变。

Q1: L1和L2正则化项的区别?

首先,我们从上面那张二维的图可以看出,对于L2-norm,其解是唯一 的,也就是绿色的那条;而对于L1-norm,其解不唯一,因此L1正则化 项,其计算难度通常会高于L2的。

其次,L1通常是比L2更容易得到稀疏输出的,会把一些不重要的特征直接 置零,至于为什么L1正则化为什么更容易得到稀疏解,





上图代表的意思就是目标函数-平方误差项的等值线和L1、 (左边是L1) ,我们正则化后的代价函数需要求解的目标就是在经验风险 和模型复杂度之间的平衡取舍,在图中形象地表示就是黑色线与彩色线的 交叉点。

对于L1范数, 其图形为菱形, 二维属性的等值线有4个角(高维的会有更 "突出来的角"更容易与平方误差项进行交叉,而这些"突出来的 角"都是在坐标轴上,即W1或则W2为0;

而对于L2范数,交叉点一般都是在某个象限中,很少有直接在坐标轴上交 叉的。

因此L1范数正则化项比L2的更容易得到稀疏解。

Q2: 各有什么优势, 如何作选择?

直接上结论:

- 1) 因为L1范数正则化项的"稀疏解"特性,L1更适合用于特征选择,找出 较为"关键"的特征,而把一些不那么重要的特征置为零。
- 2) L2范数正则化项可以产生很多参数值很小的模型,也就是说这类的模型 抗干扰的能力很强,可以适应不同的数据集,适应不同的"极端条件"。

如何作为Loss Function

讲完了作为正则化项的内容了,那么讲讲L1、L2范数作为损失函数的情 况。假设我们有一个线性回归模型,我们需要评估模型的效果,很常规 的,我们会用"距离"来衡量误差!

若使用L1-norm来衡量距离,那就是我们的LAD(Least Absolute Deviation, 最小绝对偏差), 其优化的目标函数如下:


实际意义上的解释就是预测值与真实值之间的绝对值。

若使用L2-norm,那就是我们的LSE(Least Squares Error,最小二乘误 差),其优化的目标函数如下:

针对两者的差异,可以看下表:


L1损失函数的结果更具鲁棒性,也就是说对于异常值更加不敏感。而根据 其范数 "天性", L2的求解更为简单与"唯一"。

山正刚化并不是总是输船旅解:



因为二有"制",高纯度刚制更名磁到等值综 的概算更高山西到等高线的新很少是 稀疏解阻为是在伤风限中。

3. 0例更常易得到稀疏解,但是计算复杂



Once a variable has a 0 coefficient, it has no impact on the model anymore, the model uses fewer and fewer variables. This is what we mean by a sparse solution it only uses a few variables in the dataset.

Other methods may produce a solution where many variables have small, but non-zero coefficients. These models are not sparse, since you still need all the variables to produce the solution. A sparse solution is generally preferred since you can explain your model in terms of just a few variables.